

AVISO DE PROPRIEDADE INTELECTUAL:

É vedada a distribuição ou utilização do conteúdo sem a autorização expressa, por escrito, do autor.

É permitida a manutenção e utilização por parte dos alunos da disciplina Métodos de Otimização, ministrada pelo autor do material.

Para referenciar o material, utilizar:

CARVALHO, F. G. M. Notas de aula da disciplina Métodos de Otimização. São José dos Campos - SP, 2026.

Métodos de Otimização

Introdução

Prof. Fabrício Galende Marques de Carvalho

2026/3º Período

OBJETIVOS DA UNIDADE

- ✓ Introduzir os conceitos básicos relacionados à resolução de problemas de otimização, incluindo:
 - Problemas contínuos, discretos e mistos.
 - Espaço de busca.
 - Restrições de problema.
 - Ótimo local e global.
 - Tipos de estratégia para resolução de problemas.

Estrutura da Unidade

1. O que é um problema de otimização?
2. Etapas básicas do projeto usando otimização
3. Vantagens dos algoritmos de otimização
4. Definição do problema de otimização
5. Espaço de busca e restrições
6. Ótimos locais versus ótimos globais
7. Classificação das estratégias e problemas de otimização
8. O que são metaheurísticas?
9. Exercícios e problemas.

1. O que é um problema de otimização?

Problemas de otimização são encontrados em inúmeras áreas do conhecimento.

- **Engenharia Mecânica:** Automóveis têm suas geometrias projetadas de modo a reduzir o arrasto aerodinâmico e, consequentemente reduzir o consumo de combustível.
- **Negócios:** Corporações são geridas visando a maximização dos lucros.
- **Natureza:** Processos evolutivos podem favorecer características que aumentam a sobrevivência e a reprodução dos organismos em determinado ambiente.

1. O que é um problema de otimização?

Problemas de otimização são encontrados em inúmeras áreas do conhecimento.

- **Computação:** Sistemas de software são projetados de maneira a minimizar o consumo de recursos computacionais (memória e processamento).
- **Esportes:** Treinamentos físicos são criados objetivando fazer com que os atletas obtenham melhores desempenho de força, potência e velocidade.


1. O que é um problema de otimização?

Todos os exemplos citados constituem problemas que podem se resolvidos através de otimização.

Um algoritmo de otimização é constituído por passos a serem executados de modo a buscar a melhor solução para um problema, de acordo com determinado critério.

2. Etapas Básicas do Projeto Usando Otimização

O projeto de uma solução usando otimização pode ser separado em três etapas principais:



2. Etapas Básicas do Projeto Usando Otimização

1. Primeiramente, partindo-se das especificações do problema, escolhe-se uma representação computacionalmente adequada às variáveis de projeto e gera-se uma solução (ou conjunto de soluções) inicial.
2. A solução (ou conjunto de soluções) é avaliada de acordo com determinado critério. A seguir, decide-se sobre a sua adequação.
3. Caso a solução seja adequada, interrompe-se o processo e mantém-se a solução. Caso a solução não seja adequada, modifica-se o projeto/solução e retorna-se à etapa 2.

2. Etapas Básicas do Projeto Usando Otimização

Pode-se definir, portanto, um algoritmo de otimização como aquele que busca, de forma sistemática, soluções cada vez melhores para um problema (e.g., um projeto) de acordo com um determinado critério.

Quando o algoritmo é baseado em repetição, este é executado até que uma solução adequada seja encontrada (e.g., não possa mais ser melhorada) ou até que os recursos disponíveis sejam esgotados (e.g., tempo, energia, etc.)

2. Etapas Básicas do Projeto Usando Otimização

EXEMPLO: Suponha que um profissional de sensoriamento remoto deseja detectar áreas queimadas considerando-se valores limiares para os índices espectrais tais como NDVI (*Normalized Difference Vegetation Index*) e NBR (*Normalized Burn Ratio*). Partindo-se de limiares iniciais para os índices, o profissional aplica a regra a todos os pixels de uma imagem e avalia a acurácia em relação a imagem previamente classificada. Em caso adequado (erro de classificação aceitável), mantém os limiares. Em caso inadequado, altera os limiares. Repete-se o processo de avaliação até a obtenção de um erro de classificação aceitável ou após um certo número de iterações.

3. Vantagens e Desafios dos Algoritmos de Otimização

Vantagens

- ✓ Tipicamente, definem um processo sistemático de projeto ou obtenção de solução (i.e., possuem etapas claramente definidas).
- ✓ Como são automatizados, reduzem as chances de erros de projeto por fatores humanos (e.g., seleção de uma solução "boa" a partir de falsa intuição).
- ✓ Em muitos casos, aceleram consideravelmente o tempo de projeto (e.g., evita processos de tentativa e erro).
- ✓ São aplicáveis a um número alto de variáveis de projeto e restrições.

3. Vantagens e Desafios dos Algoritmos de Otimização

Desafios

- ✓ Muitos algoritmos de otimização iterativos, são altamente dependentes de recursos computacionais. (e.g. algoritmos genéticos podem consumir quantidades substanciais de memória e processamento).
- ✓ Nem todo algoritmo de otimização possui garantia de obtenção da melhor solução (e.g. Uma solução inicial ruim pode fazer com que o algoritmo nunca chegue próximo da melhor solução).
- ✓ Para problemas com muitas variáveis e objetivos, deve-se ter cuidado na seleção da representação e do critério de escolha das soluções.

4. Definição do Problema de Otimização

Matematicamente, um problema de otimização pode ser modelado da seguinte forma:

$$\left. \begin{array}{l} \text{minimizar} \quad f(\vec{x}) \\ \text{sujeito a} \quad \vec{x} \in \mathcal{X} \end{array} \right\} \quad \text{ou} \quad \left\{ \begin{array}{l} \min_{\vec{x} \in \mathcal{X}} f(\vec{x}) \\ \min_{x \in \mathcal{X}} f(x) \end{array} \right.$$

4. Definição do Problema de Otimização


Nas expressões anteriores, $\mathbf{x}$ representa a solução ou as variáveis de projeto (também chamado de design point), $\mathbf{X}$ é chamado de conjunto factível (*feasible set*) e $f(\mathbf{x})$ é denominada de função objetivo.

Quando um valor específico de $\mathbf{x}$ minimiza o valor da função objetivo, chama-se esse valor de minimizador e comumente denota-se $\mathbf{x}^*$.

O valor assumido pela função objetivo em $\mathbf{x}^*$, ou seja, $f(\mathbf{x}^*)$, é denominado de mínimo ou valor ótimo.

4. Definição do Problema de Otimização

Exemplo: Seja a função $f(x) = x^2$. Para essa função, tem-se claramente que $\mathbf{x}^* = 0$ e $\mathbf{f}(\mathbf{x}^*) = 0$.



4. Definição do Problema de Otimização

Um problema que é formulado como problema de maximização pode facilmente ser modelado como um problema de minimização. Para isso, basta fazer:

$$\max_{x \in \mathcal{X}} f(x) \Leftrightarrow \min_{x \in \mathcal{X}} [-f(x)]$$

4. Definição do Problema de Otimização

Dependendo da modelagem matemática e, consequentemente, computacional, o problema de otimização pode se tornar mais fácil ou difícil, dado que isso afetará as variáveis de projeto, o conjunto factível e, consequentemente, a função objetivo.

5. Espaço de busca e restrições

Na resolução de um problema de otimização, o espaço de busca determina todos os valores que podem ser considerados pelo método de otimização.

Quando se considera um subconjunto do espaço de busca que satisfaz a um determinado conjunto de restrições, tem-se o que se chama de conjunto factível.

5. Espaço de busca e restrições

Exemplo: Determinar as dimensões de uma placa de circuitos de um computador de bordo de modo que todos os componentes possam ser soldados e que a superfície da placa seja minimizada.

Se b e h são as dimensões da placa, claramente o problema possui um espaço de busca tal que b e $h \in R$ e, adicionalmente

$$b > 0$$

$$h > 0$$

5. Espaço de busca e restrições

Exemplo: (Continuação)

Se a maior dimensão para alojar a placa dentro do computador for d , então o espaço de busca fica restrito a

$$d \geq b > 0$$

$$d \geq h > 0$$

Essas duas desigualdades podem ser re-escritas da forma

$$0 < g_i(\mathbf{x}) \leq d, \quad i = 0, 1$$

sendo $g_1(\mathbf{x}) = b$ e $g_2(\mathbf{x}) = h$, $[x_1, x_2]^T = [b, h]^T$.

5. Espaço de busca e restrições

A desigualdade expressa por

$$0 < g_i(\mathbf{x}) \leq d, \quad i = 0, 1, \dots, n$$

constitui aquilo que se chama de restrição para o problema de otimização.

Uma restrição corresponde a uma limitação para o conjunto de possíveis soluções para o problema de otimização em questão.

5. Espaço de busca e restrições

Restrições para o problema de otimização podem corresponder a diversos fatores, exemplos incluem:

- Disponibilidade de capital (e.g., Investimentos em políticas públicas não podem violar o orçamento governamental).
- Disponibilidade de material (e.g., aproveitamento de recursos em linha de produção, tais como recortes ou sobras de material)
- Factibilidade física (e.g., não pode haver um volume negativo associado a um projeto de um recipiente para acondicionar determinado líquido).


6. Ótimos locais versus ótimos globais

Seja $\mathbf{x}^* \in \mathbf{X}$ tal que

$$f(\mathbf{x}^*) \leq f(\mathbf{x}) , \quad \forall \mathbf{x} \in \mathbf{X}$$

Então o minimizador $\mathbf{x}^*$ é chamado de ótimo global.

Exemplo: $x = 0$ para $f(x) = x^2$



6. Ótimos locais versus ótimos globais

Seja $\mathbf{x}^* \in \mathbf{X}$ tal que


$$f(\mathbf{x}^*) \leq f(\mathbf{x}), \quad \forall \mathbf{x} \in \mathbf{X} \mid \|\mathbf{x} - \mathbf{x}^*\| < \varepsilon$$

Então o minimizador $\mathbf{x}^*$ é chamado de ótimo local.

O número ε é chamado de raio de vizinhança. Ou seja, um ótimo $\mathbf{x}^*$ é dito local se existe uma vizinhança de raio ε para o qual a função objetivo não é menor do que $f(\mathbf{x}^*)$.

6. Ótimos locais versus ótimos globais


Exemplo 1: A função $f(\mathbf{x}) = x^2 - \cos(2\pi x) + 1$ possui um ótimo local em $\mathbf{x}^* = 0.95105$ ($f(\mathbf{x}) = 0.95142$). Para esse caso, um valor possível para ε é 0.5.




6. Ótimos locais versus ótimos globais

Exemplo 2: A função $f(\mathbf{x}) = \cos(x_1) + \cos(x_2)$ possui um ótimo local em $\mathbf{x}^* = [\pi, \pi]$ ($f(\mathbf{x}) = -1$). Para esse caso, a vizinhança pode ser definida por $B_{0.5}(\pi, \pi) = \{(x_1, x_2) \mid (x_1 - \pi)^2 + (x_2 - \pi)^2 < (0.5)^2\}$.

6. Ótimos locais versus ótimos globais



6. Ótimos locais versus ótimos globais



7. Classificação dos problemas e estratégias de otimização

7.1. Classificação dos Problemas

Os problemas de otimização podem ser classificados de acordo com vários critérios que, em geral, dependem das restrições e da forma da função objetivo.

7.1.1. Quanto à existência de restrições:

- **Irrestritos:** São problemas em que não há qualquer restrição que deve ser satisfeita pelas variáveis de projeto.

Exemplo: Ajuste de parâmetros para corrigir o viés e a escala de um modelo experimental baseado em dados.

7. Classificação dos problemas e estratégias de otimização

7.1.1 Quanto à existência de restrições:

- **Restritos:** há ao menos uma restrição do tipo igualdade ou de desigualdade a ser considerada.

Exemplo: obtenção de limiar (L) para determinação de áreas com maior probabilidade de vegetação, com base no NDVI ($-1 \leq L \leq +1$).

7. Classificação dos problemas e estratégias de otimização

7.1.2. Quanto à forma da função objetivo e restrições:

- **Otimização linear:** Função objetivo e restrições com formato linear
- **Otimização não-linear:** Há ao menos uma restrição não linear ou o formato de $f(\mathbf{x})$ é não linear.

7. Classificação dos problemas e estratégias de otimização

7.1.2. Quanto à forma da função objetivo:

OBS: A otimização quadrática é um caso particular de um problema de otimização em que a função objetivo é quadrática e as restrições são funções lineares das variáveis de projeto.

7. Classificação dos problemas e estratégias de otimização

7.1.3. Quanto à convexidade:

- **Otimização convexa:** Tanto a função objetivo quanto o conjunto factível possuem propriedade de convexidade. Em um problema de minimização convexa, todo ótimo local também é ótimo global.

Para provar que uma função é convexa, deve-se provar que

$$f(\lambda \mathbf{x}_1 + (1-\lambda)\mathbf{x}_2) \leq \lambda f(\mathbf{x}_1) + (1-\lambda)f(\mathbf{x}_2)$$
$$\lambda \in [0, 1], \forall \mathbf{x}_1, \mathbf{x}_2$$

7. Classificação dos problemas e estratégias de otimização

7.1.3.Quanto à convexidade:

OBS: Para que um conjunto factível seja convexo, qualquer segmento que conecte pontos pertencentes ao conjunto deve pertencer, também, ao conjunto.

Para uma função convexa, qualquer segmento que conecte dois pontos do gráfico da função gerará um segmento que se situará acima ou sobre o gráfico da função.

7. Classificação dos problemas e estratégias de otimização

7.1.3. Quanto à convexidade:

- **Otimização convexa:**

Exemplo: A função $f(x) = x^2$ é uma função convexa.

O conjunto $\mathbf{X} = [-1, 1]$ é um conjunto convexo.

O problema de minimizar a função $f(x)$ com $x \in \mathbf{X}$ é um problema de otimização convexa.

7. Classificação dos problemas e estratégias de otimização

7.1.3. Quanto à convexidade:

- **Otimização não convexa:** É aquele para o qual ou a função objetivo ou o conjunto factível (ou ambos) não é (são) convexo(s).

Exemplo: Minimizar a função $f(x) = \cos(x)$ não é um problema de otimização convexa.

Observar o gráfico e/ou provar que $\cos(x)$ não é convexa.

7. Classificação dos problemas e estratégias de otimização

7.1.3. Quanto à convexidade:

- **Otimização não convexa:**

Exemplo: Minimizar a função $f(x) = x^2$, $x \in X = [-2, -1] \cup [1, 2]$ não é um problema de otimização convexa pois o conjunto admissível não é convexo.

7. Classificação dos problemas e estratégias de otimização

7.1.4. Quanto à natureza dos objetivos de otimização:

Otimização de objetivo único: Existe uma única função objetivo que define o critério pelo qual as soluções são avaliadas.

Exemplo: Determinação dos parâmetros de uma RNA de modo a minimizar o erro de classificação.

7. Classificação dos problemas e estratégias de otimização

7.1.4. Quanto à natureza dos objetivos de otimização:


Otimização multiobjetivo: É aquele em que, simultaneamente, se deseja otimizar duas ou mais funções. Em geral, problemas de otimização desse tipo possuem conflito, ou seja, minimizar somente uma das funções faz com que as outras aumentem.

Exemplo: Otimização multiobjetivo de uma rede neural: determinar simultaneamente os parâmetros e a arquitetura de uma rede neural de modo a minimizar o erro de classificação e o erro de validação cruzada


7. Classificação dos problemas e estratégias de otimização

7.1.4. Quanto à natureza dos objetivos de otimização:

Otimização multiobjetivo:



Arquitetura [2-6-1]



Arquitetura [2-3-1]

7. Classificação dos problemas e estratégias de otimização

7.1.4. Quanto à natureza dos objetivos de otimização:

Observação: O número de variáveis de projeto (ou variáveis de decisão) não possui correspondência direta com o número de funções objetivo. Por exemplo, é possível otimizar simultaneamente os parâmetros e a arquitetura de uma rede neural considerando-se apenas a minimização do erro de classificação.

$$[w_1, w_2, \dots, w_n, n_1, n_2, n_3, \dots, n_n] \Rightarrow f(w, n)$$

7. Classificação dos problemas e estratégias de otimização

7.1.5. Quanto ao tipo das variáveis envolvidas:

- **Problemas contínuos:** As variáveis de projeto podem assumir valores reais.

Exemplo: Ajuste de ganho e viés para um modelo que corrija valores estimados para material particulado, obtido através de sensoriamento remoto, considerando dados de estações.

$$y_c = \alpha y_{sr} + \beta$$

7. Classificação dos problemas e estratégias de otimização

7.1.5. Quanto ao tipo das variáveis envolvidas:

- **Problemas discretos:** As variáveis de projeto assumem valores mapeáveis para inteiros (discretos).

Exemplo: Escolha de arquitetura de uma rede neural de modo a se minimizar o erro de validação cruzada. Soluções para o problema poderiam ser, por exemplo $\{[3, 6, 1], [3, 10, 1], [4, 4, 1]\}$

7. Classificação dos problemas e estratégias de otimização

7.1.5. Quanto ao tipo das variáveis envolvidas:

- **Problemas mistos:** São problemas onde podem aparecer tanto variáveis de decisão que são discretas como variáveis contínuas.

Exemplo: Escolher os índices espectrais (e.g., NDVI, NBR, DNBR e NDWI) e os limiares (L_1 , L_2 , L_3 , L_4) para classificar áreas com maior probabilidade de vegetação.

7. Classificação dos problemas e estratégias de otimização

7.2. Classificação das Estratégias de Otimização

- ✓ Assim como existem diferentes classes de problemas de otimização, existem diferentes estratégias e técnicas que podem ser empregadas para resolvê-los.
- ✓ Essas estratégias podem ser classificadas segundo diferentes critérios, como o número de soluções manipuladas simultaneamente, o tipo de informação utilizada durante a busca, a natureza da estratégia de busca e o grau de aleatoriedade empregado.

7. Classificação dos problemas e estratégias de otimização


7.2.1. Quanto ao número de soluções manipuladas:

Métodos de soluções únicas: São métodos que examinam uma única solução por vez. A cada iteração o método tenta melhorar a solução em relação à solução anterior.

7. Classificação dos problemas e estratégias de otimização

7.2.1. Quanto ao número de soluções manipuladas:

Métodos de soluções únicas: Exemplo: gradiente.



7. Classificação dos problemas e estratégias de otimização

7.2.1. Quanto ao número de soluções manipuladas:

Métodos populacionais: São métodos que, a cada iteração, manipulam mais de uma solução para o problema. A alteração do conjunto de soluções envolve, em geral, efeito individual e efeito coletivo.

7. Classificação dos problemas e estratégias de otimização

7.2.1. Quanto ao número de soluções manipuladas:

Métodos populacionais: Exemplo: Algoritmos Genéticos



7. Classificação dos problemas e estratégias de otimização

7.2.2.Quanto à informação utilizada:

Métodos baseados em derivadas: São métodos que fazem uso de $f'(x)$ ou $f'(x)$ e $f''(x)$.

Exemplos:

- O método do gradiente utiliza somente a primeira derivada e é dito método de primeira ordem.
- O método de newton utiliza a derivada de segunda ordem.

7. Classificação dos problemas e estratégias de otimização

7.2.2.Quanto à informação utilizada:

Métodos que apenas avaliam a função objetivo:

Não fazem uso de derivadas. Usam somente o valor da função objetivo para orientar a busca pela solução.

Exemplos: Otimização por enxame de partículas, algoritmos genéticos.

7. Classificação dos problemas e estratégias de otimização

7.2.3. Quanto à natureza da busca:

Métodos Locais: São métodos que partem de uma ou mais soluções locais e buscam melhorá-las a partir de uma vizinhança dessas soluções.

Exemplos: Método do gradiente, método hill climbing e método de Nelder-Mead.

7. Classificação dos problemas e estratégias de otimização

7.2.3. Quanto à natureza da busca:

Métodos Globais: São métodos que buscam explorar diferentes regiões do espaço de busca ao invés de se concentrar apenas na vizinhança de uma determinada solução ou conjunto de soluções

Exemplos: Algoritmos genéticos, otimização por enxame de partículas (PSO)

7. Classificação dos problemas e estratégias de otimização

7.2.4.Quanto à natureza determinística ou estocástica:

Métodos Determinísticos: Produzem a mesma sequência de soluções quando fixadas as condições iniciais.

Exemplos:

- Método do gradiente.
- Busca por vizinhança variável (Variable Neighborhood Search).
- Hill climbing.

7. Classificação dos problemas e estratégias de otimização

7.2.4.Quanto à natureza determinística ou estocástica:

Métodos Estocásticos: podem produzir sequências diferentes de soluções mesmo quando fixadas as condições iniciais e parâmetros. Esses algoritmos utilizam a aleatoriedade para produzir variações nas soluções de modo a melhorar a exploração do espaço de busca.

Exemplos:

- Método do gradiente estocástico (SGD).
- Algoritmos genéticos.
- Otimização por enxame de partículas.

8. O que são metaheurísticas?

Em otimização, **heurísticas** são estratégias práticas para encontrar boas soluções para um problema em particular.

Exemplo: escolher um limiar de NDVI a partir de 0.6 como um indicativo de ocorrência de vegetação.



NDVI = 0.7



NDVI = 0.05

8. O que são metaheurísticas?

Metaheurísticas são combinações de estratégias de exploração e intensificação que fornecem uma estrutura algorítmica geral para a resolução de vários problemas.

São particularmente úteis em **problemas inversos**.


Exemplo: Utilizar uma metaheurística para encontrar o limiar do NDVI que minimize o erro de classificação dos pixels de uma imagem previamente rotulada. A metaheurística pode gerar um conjunto de soluções iniciais e combiná-las de modo a obter soluções que minimizem cada vez mais o erro de classificação.

9. EXERCÍCIOS E PROBLEMAS

Para começarmos: **Grid Search**.

Busca exaustiva/sistemática.

Como definir a grade e, feito isso, qual a consequência no desempenho da busca, em especial em espaços de busca de alta dimensionalidade.




9. EXERCÍCIOS E PROBLEMAS

Para começarmos: **Variable Neighborhood Search**.

Metaheurística de busca por vizinhança.

Como definir adequadamente as vizinhanças e as variações na solução candidata?




9. EXERCÍCIOS E PROBLEMAS

Para começarmos: **Nelder Mead**.

Mecanismo local sem derivadas.

Quando realizar as contrações, expansões, reflexões e reduções?



9. EXERCÍCIOS E PROBLEMAS

Para serem resolvidos e apresentados na próxima semana.